

Scorm: Lexical Analysis

Teacher: MEng. Tran Ngoc Bao Duy

Content

1. **Token and Regular Expression**
2. **How to recognize**
 - a. **ad hoc**
 - b. **Finite automation**
3. **ANTLR**

I. Token and Regular Expression

Introduction

- Lexical Analysis (scanner): nhận đầu vào là một chuỗi các kí tự và trả ra chuỗi các từ loại.
- "Tôi đi học" —lexical analysis→ "tôi", "đi", "học"
- Chuỗi kí tự → tách ra thành các từ → phân thành các từ loại
- Từ loại là khối cơ bản nhất để build một chương trình. Việc phân tích từ loại là bắt buộc khi muốn xây dựng compiler.

Token

- **Định nghĩa:** Tokens là một khối cơ bản nhất của chương trình, là dạng chuỗi ngắn nhất với nghĩa độc lập. Tokens thường mang 2 nghĩa:
 - **Nghĩa tổng quát:** lớp/nhóm của token.
 - **Chuỗi cụ thể (lexeme):** chính dãy kí tự trong mã nguồn.
- Trong ngôn ngữ lập trình C , có hơn 100 tokens khác nhau:
 - 44 keywords: Từ khóa do ngôn ngữ định trước: `if, else, while, ...`
 - Rất nhiều identifiers (`my_variable, your_type, sizeof, printf ...`)
 - interger
 - floating-point
 - character
- Thông thường còn các loại token sau:

- **LITERAL**: hằng.
 - INT_LITERAL: 123, 45, ...
 - FLOAT_LITERAL: 1.23, 4.55, ...
 - STRING_LITERAL: "hi", "HELLO"
 - CHAR_LITERAL: "a", "b"...
 - BOOL_LITERAL: True/False
 - null/nil
- **OPERATOR**: toán tử.
 - + - * /
 - == | != | > | <
 - ! | &&
 - = | += | ++
- **SEPERATOR**: dấu câu
 - () [] { } , ; : →
- **SPECIAL TOKEN**

Sample:

- Có đoạn mã sau: `int total = price + 42;`
- Ta có thể phân chia thành 7 token:
 - KEYWORD: "int"
 - ID: "total"
 - OP_ASSIGN: "="
 - ID: "price"
 - OP_PLUS: "+"
 - INT_LITERAL: 42
 - SEMICOLON: ";"

RegEx

- biểu thức chính quy sử dụng để biểu diễn các từ vựng. RegEx có dạng:
 - **Một kí tự**
 - **Một chuỗi rỗng**. Kí hiệu là **epsilon** ϵ .
 - **2 biểu thức chính quy đứng cạnh nhau (nối chuỗi)**. Ví dụ: ab có a đứng cạnh b → Đây là mô tả của chuỗi "ab".

- **Đứng cạnh nhau và cách nhau một dấu |** → Chấp nhận một trong hai kí tự. Ví dụ: $A | B \rightarrow$ Chấp nhận kí tự A hoặc kí tự B
- **Biểu thức chính quy dạng một kí tự kèm theo dấu " * "** → biểu diễn cho việc có 0 hoặc 1 hoặc nhiều kí tự.

$$a^* = 0 | a | aa..a$$

- **Biểu thức chính quy dạng một kí tự kèm theo dấu " + "** → biểu diễn cho việc có 1 hoặc nhiều kí tự.

$$a^+ \Leftrightarrow a | aa..a$$

- **Ngoài ra ta sử dụng ngoặc tròn () để thể hiện độ ưu tiên.**

Tóm lại, vai trò của lexer:

xác định các kí tự và group thành từ

Bỏ qua kí tự gọi là space

Ghi nhận lại vị trí các token để sử dụng cho các page tiếp theo


Mỗi lần gọi lexer, lexer cần trả về token đó là token gì.

- Lexer còn có tên gọi khác là scanner, cả hai đều là tên của bộ phân tích từ RegEx thành các token.

Quiz:

1. **Cho đoạn mã C sau:** `i = a = b*34 + c5;` , số token trả về là?
 - a. 7
 - b. **10**
 - c. Một giá trị khác
 - d. 9
2. **Cho đoạn mã viết bằng ngôn ngữ C sau:** `inc=-100;` , có bao nhiêu từ được bộ phân tách từ vựng tách ra từ mã trên?
 - a. **5**
 - b. 4
 - c. Tùy theo trình biên dịch
 - d. 3
3. **Các bước để chuyển từ một biểu thức chính quy sang automata hữu hạn?**
 - a. **Chuyển từ NFA sang DFA**
 - b. Chuyển từ DFA sang NFA

- c. **Chuyển từ RegEx sang NFA**
 - d. **Tối ưu hóa DFA**
4. **Biểu thức chính quy nào mô tả ngôn ngữ bao gồm các chuỗi của token INTEGER, vốn là một dãy các chữ số?**
- a. $-?[0-9]^+$
 - b. $[+-][0-9]^+$
 - c. $[0-9]^*$
 - d. **$0 \mid [1-9][0-9]^*$**
 - e. **$[0-9]^+$**
5. **Cho automata sau:**







- Các phát biểu sau là đúng hay sai?**
- a. **Chuỗi aaaaabaaa được chấp nhận bởi automata trên.**
 - a. **True**
 - b. False
 - b. **Chuỗi aaaaabb được chấp nhận bởi automata trên.**
 - a. True
 - b. **False**
 - c. **Automata trên chấp nhận ngôn ngữ bao gồm các string có chứa b lẻ.**
 - a. **True**
 - b. False
6. **NFA khác DFA ở điểm?**
- a. NFA có nhiều trạng thái kết thúc
 - b. **NFA cho phép chuyển tới trạng thái tiếp theo với input rỗng**
 - c. NFA không cho phép nhiều trạng thái kết thúc
 - d. **Với trạng thái hiện tại và một input symbol, NFA cho phép có nhiều trạng thái tiếp theo.**

7. RegEx nào mô tả ngôn ngữ bao gồm các kí tự sau: $\geq, >, <, \leq$?

- a. $(< | >) = ?$
- b. $[< >] = ?$
- c. $(< >) = ?$
- d. $> | > = | < | < =$
- e. $> | < = ?$
- f. $[< | >] = ?$

8. Đây là NFA của RegEx $(a | b)c$ sử dụng thuật toán Thompson?

- a. Hình 1.
- b. **Hình 2**
- c. Hình 3
- d. Hình 4



9. Đây là mô tả ANTLR đúng của một HEX token biểu diễn một số HEX trong ngôn ngữ C? Ghi nhớ rằng một số HEX ở C bắt đầu với `0x` hoặc `0X` và tiếp theo là các số hoặc chữ (in hoa hoặc không in hoa) từ `a` tới `f`.

- a. `hex: '0'[xX][0-9a-fA-F]+;`
- b. `HEX: [0][xX][0-9a-fA-F]+;`
- c. `HEX: 0[xX][0-9a-fA-F]+;`
- d. `HEX: '0'[xX][0-9a-fA-F]+;`


10. Cho đoạn code C sau: `a[12] = inc * (dec - 1);`, Có bao nhiêu token được tạo ra từ bộ phân tích từ vựng cho câu trên?

- a. 12
- b. **13**
- c. 14
- d. 15

11. RegEx nào sau đây match với ngôn ngữ gồm 4 kí tự: a, b, c, d ?

- a. `[a | b | c | d]`
- b. `(abcd)`
- c. **`[a-d]`**
- d. `(a-d)`

12. Cho automata sau:



Tập K trạng thái của automata trên là? $\rightarrow \{0,1,2,3\}$

Tập Σ input của automata trên là? $\rightarrow \{a,b\}$

Trạng thái bắt đầu s của automata trên là? $\rightarrow 0$

Tập F biểu thị trạng thái kết thúc của automata trên là? $\rightarrow \{2,3\}$

Hàm chuyển đổi δ được cho dưới bảng sau. Hãy điền vào chỗ trống.


K	input	function (k, input)
0	a	3
0	b	1
1	a	1
1	b	2
2	a	2
2	b	3
3	a	3

13. Cho đoạn code C sau: `int a, b = 120, c[10];` .

Có bao nhiêu token được sinh ra bởi bộ phân tích cú pháp từ vựng?

- a. 10
- b. 11
- c. **12**
- d. 13

14. Chọn biểu thức chính quy biểu diễn ngôn ngữ được nhận dạng bởi DFA sau:



- a. **$a^*b(aa|ba^*b)^*a$**
- b. $a+ba^*(ba+ba^*)^*$
- c. $a^*ba^*(ba^*ba^*)^*$

d. $a*ba+(ba*ba+)+$

15. Cho biểu thức chính quy sao cho biểu diễn được các chuỗi thuộc tập cho phép và KHÔNG biểu diễn các chuỗi thuộc tập không cho phép:

Tập cho phép:

3.14159

-255.34

128

1.9e10

123,340.00

Tập không cho phép:

720p

4.e5

- a. $[+-]?[0-9]([0-9][0-9]?)(,[0-9][0-9][0-9])*(\.[0-9]+([eE][+-]?[0-9]+)?)?$
- b. $-?([0-9],)+(\.[0-9]+(e[0-9]+)?)?$
- c. $-?[0-9,]+(\.[0-9]+(e[0-9]+)?)?$
- d. $[+-]?[0-9]([0-9][0-9]?)(,[0-9][0-9][0-9])*(\.[0-9]*([eE][+-]?[0-9]+)?)?$ (sai 4.e5)
- e. $[+-]?[0-9]([0-9][0-9]?)(,[0-9][0-9][0-9])*(\.[0-9]+([eE][+-]?[0-9]+)?)?$

16. Cho biểu thức chính quy sau: $(aa)^*(ab)?(bb)^*$. Hãy chọn các chuỗi thỏa biểu thức chính quy trên?

- a. a
- b. aab
- c. **abbb**
- d. $\in$.


17. Cho biểu thức chính quy sau: $(aa)+(ab)?(bb)+$
Hãy chọn các chuỗi thỏa biểu thức chính quy trên?

- a. aab
- b. $\in$
- c. **aabb**
- d. aaabb

18. **Hãy chọn các vai trò của bộ phân tích từ vựng?**

- a. **Tách các chuỗi con ứng với các tokens**
- b. Kiểm tra ràng buộc như biến phải được khai báo trước khi sử dụng
- c. **Loại bỏ các chuỗi con ứng với khoảng trắng (như dấu blank, tab, chú thích, ...)**
- d. Xác định cấu trúc của chuỗi tokens có phù hợp không (syntax analysis)

19. **Hãy chọn các chuỗi nhập thỏa DFA sau:**



- a. **ba**
- b. aababbaa
- c. aaabaabba
- d. **baaababa**

20. **Cho biết có bao nhiêu token được trả về bởi quá trình phân tích từ vựng cho chuỗi nhập sau viết trên ngôn ngữ C:** `*p += q[12 * a] + -24 * b ++;`

→ Đáp án: **16** (**+=, ++** đếm là 1)

21. **Hãy cho biết số token được phân tích từ vựng trả về khi phân tích từ vựng cho chuỗi (gồm 2 dòng) sau được viết trên ngôn ngữ C:**

```
/* Day la doan ma */  
if (!a[foo(-2)]) return x[m*foo(3)];
```

→ Đáp án: **23**

22. Cho biểu thức chính quy biểu diễn một số nguyên thập phân viết trên ngôn ngữ C như sau:

0 | [1-9][0-9]*

Hãy chọn những số nguyên thập phân hợp lệ theo biểu thức chính quy trên?

- a. -12
- b. 00
- c. **0**
- d. **102**

Hãy chọn biểu thức chính qui phù hợp mô tả ngôn ngữ trên tập {a,b} gồm các chuỗi có số lẻ số chữ a?

Select one or more:

- ☐ a. $b^*a^*b^*a^*b^*a^*b^*$
- ☐ b. $a(aa)^+$
- ☐ c. $b^*a(b^*ab^*a)^*b^*$
- ☐ d. $b^*ab^*(ab^*ab^*)^*$

c, d.

Hãy chọn biểu thức chính qui hợp lệ để mô tả cho một hằng nguyên của Pascal? Nhắc lại một hằng nguyên của Pascal là một chuỗi không rỗng các ký số từ 0 đến 9.

Select one or more:

- ☐ a. $0 | [1-9][0-9]^*$
- ☐ b. $(+|-)?[0-9]^+$
- ☐ c. $[0-9]^+$
- ☐ d. $[0-9]^*$

c

Hãy cho biết số token được phân tích từ vệtng trả về khi phân tích từ vệtng cho chuỗi sau viết trên ngôn ngữ Python:

if a >= b: x = d if b <= c else e

Answer:

